АНАЛИЗ ЛЕКСИКО-СТИЛИСТИЧЕСКИХ ОСОБЕННОСТЕЙ РУССКИХ НАРОДНЫХ СКАЗОК С ПОМОЩЬЮ МЕТОДОВ МАШИННОГО ОБУЧЕНИЯ

Ключевые слова: компьютерная лингвистика, корпусная лингвистика, русские народные сказки, лексико-статистический анализ, машинное обучение, стилометрия, морфология сказки, метод TF-IDF, анализ тональности, цифровая гуманитаристика.

2025 г.

Оглавление

Введение...……...……..…3

Основная часть……...……..….……..4

1. Теоретическая часть...…….…….....……..…..…….4

2. Методология и данные.....……..…….……...…..5

3. Практическая часть.……..…..……..……...…...8

3.1. Частотный анализ……..……...…8

3.2. Ключевой анализ…….……...10

3.3 Анализ тональности…….…..…11

3.4. Обсуждение результатов……..….……12

Заключение…….……..…….....15

Библиографический список……..……..…....16

Приложения……..…….17

Введение

Русские народные сказки, являясь квинтэссенцией коллективного опыта, сохраняют уникальный культурный код. Однако их лингвистический анализ часто ограничивается качественными методами. В данном исследовании предлагается дополнить традиционное литературоведение методами машинного обучения, чтобы выявить скрытые лексико-статистические закономерности, неочевидные при «ручном» анализе.

Работа посвящена анализу русских народных сказок и выявлению в них лексико-стилистических паттернов, которые формируют уникальный характер национального повествования.

Актуальность работы определяется применением компьютерных методов анализа, в частности, методов машинного обучения. Применение машинного обучения позволяет не только обработать весь корпус сказок как «большие данные», но и выявить в них скрытые паттерны, минуя субъективизм исследователя.

Объектом исследования выступает корпус русских народных сказок, составленный на основе сборника А. Н. Афанасьева “Народные русские сказки” (издание 1984-1985 годов) и дополненный авторскими лингвистическими пометами.

Предмет исследования: лексико-статистические закономерности в сказках.

Целью научно-исследовательской работы является выявление и классификация стилистических паттернов, характерных для русских народных сказок.

Основная часть

1. Теоретическая часть

Теоретической основой для данного исследования послужила морфологическая теория сказки В. Я. Проппа. В своей фундаментальной работе «Морфология волшебной сказки» Пропп выделил инвариантную структуру сказочного нарратива, разложив его на последовательность функций действующих лиц [1]. Этот подход позволил перейти от описания сюжетного разнообразия к анализу глубинной повествовательной структуры, что является методологической основой для нашего поиска лексико-статистических инвариантов.

С развитием цифровых технологий методы компьютерной лингвистики и стилометрии стали активно применяться для анализа художественных и фольклорных текстов. В области цифровой лингвистики работы демонстрируют возможности выявления частотных паттернов, коллокаций и ключевых слов в больших массивах текстов [2]. Стилометрия, используя статистические методы для идентификации авторского стиля, доказала свою эффективность в задачах атрибуции текстов и анализа стилистических особенностей.

Применительно к русскому фольклору можно отметить ряд исследований, направленных на количественный анализ сказок [3]. Однако в большинстве случаев подобные исследования либо ограничиваются частотным анализом, либо используют готовые, но неспециализированные корпуса.

Новизна настоящего исследования заключается в симбиозе классической фольклористики и современных методов машинного обучения на основе авторского размеченного датасета.

В отличие от предыдущих работ, в данной работе используется целенаправленно созданный и жанрово размеченный корпус русских народных сказок, что позволяет проводить сравнительный анализ не на уровне всего фольклорного массива, а на уровне жанров. Кроме того, был

применен комплекс машинных методов: от классического частотного анализа и TF-IDF для выявления ключевых слов до анализа тональности, что позволяет получить многомерную характеристику текстов, а корректность количественных показателей оценивалась через призму качественной теории В.Я. Проппа.ъ

Данное исследование занимает промежуточную позицию: мы не подменяем традиционное литературоведение, а усиливаем его точными методами. Такой симбиоз позволяет предложить интерпретируемый количественный подход к фольклору, где каждая статистическая аномалия находит объяснение в теории Проппа.

2. Методология и данные

В основу исследования положен корпус из 549 русских народных сказок, составленный и систематизированный автором настоящей работы. Проведена самостоятельная классификация текстов по параметрам жанровой принадлежности, основным персонажам и тематике. Несмотря на ограниченный объем, выборка обладает репрезентативностью, так как охватывает ключевые жанровые разновидности (волшебные, бытовые, кумулятивные сказки и сказки о животных) и воспроизводит основные сюжетные модели русского фольклорного канона.

Перед проведением лингвистического анализа была проведена предобработка текстов, а именно:

1. приведение к нижнему регистру;
2. удаление цифр и спецсимволов;
3. токенизация;
4. лемматизация;
5. удаление стоп-слов.

Отбор стоп-слов был осуществлен на основе стандартного набора для русского языка из библиотеки NLTK.

Для проведения лексического и стилистического анализов был разработан комплекс программных модулей на языке Python с использованием следующих технологий и библиотек:

1. библиотека pandas для работы с структурированными данными, в том числе с загрузкой, фильтрацией и агрегацией данных.
2. библиотека nltk (Natural Language Toolkit) для токенизации и использования стоп-слов.
3. библиотека pymorphy2 для морфологического анализа и лемматизации русскоязычных текстов.

4. библиотека scikit-learn для реализации метода TF-IDF и векторизации текстов.
5. библиотеки matplotlib и seaborn для визуализации результатов анализа, wordcloud для генерации облаков слов.

Каждый этап анализа (частотный анализ, анализ ключевых слов, анализ тональности) сопровождался разработкой отдельного программного кода, что обеспечило воспроизводимость исследования и возможность его масштабируемости. Код и корпус помеченных сказок представлены в открытом доступе на Гитхабе [4].

Практическая часть

3.1. Частотный анализ

Проведенный частотный анализ позволил выявить ключевые лексические доминанты русского сказочного нарратива. Результаты демонстрируют устойчивый тематический каркас, организованный вокруг нескольких смысловых кластеров.

Так, в процессе исследования можно обратить внимание на коммуникативно-действенную природу сказок. Ядро высокочастотной лексики формируют:

1. Глаголы коммуникации и действия: говорить (3610), стать (2476), пойти (1829), взять (1787), идти (1471), сказать (1411).
2. Антропонимика: Иван (2578), царь (2379), царевич (2340).
3. Социальные и семейные роли: сын (1467), брат (1111), старик (1008), царевна (1003), старуха (782), дочь (780).
4. Бытовая и природная лексика: конь (1053), домой (887), день (828), лес (776), вода (767).

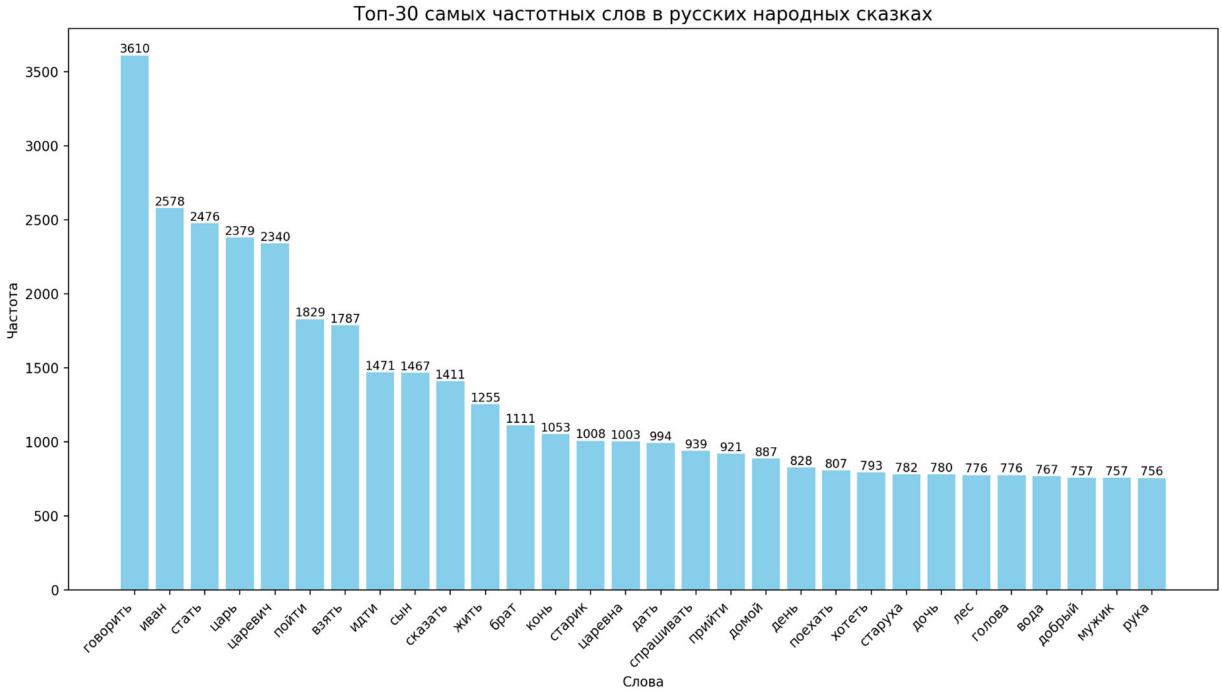

1. Распределение наиболее частых слов в корпусе.

Структурный анализ частей речи выявил абсолютное доминирование существительных (45.5%) и глагольных форм (36.9%), что составляет в сумме более 82% всего лексикона и подтверждает предметно-действенный характер сказочного повествования. Прилагательные (10.1%) и наречия (4.8%) занимают следующие за существительными и глагольными формами позиции.

Жанровая дифференциация в свою очередь позволила выяснить, что в сказках о животных чаще всего фигурируют волк, лиса и медведь; в волшебных сказках используется лексика, связанная с аристократией и властью (Иван, царевич, царь); в бытовых сказках – социально-коммуникативная направленность тематика (говорить, стать, мужик, царь, брат); а в кумулятивных – акцент на базовых действиях (жить, дать, прийти).

Списки частотных слов по общему рейтингу и по жанровым категориям вынесены в Приложение 1 и Приложение 2 соответственно.

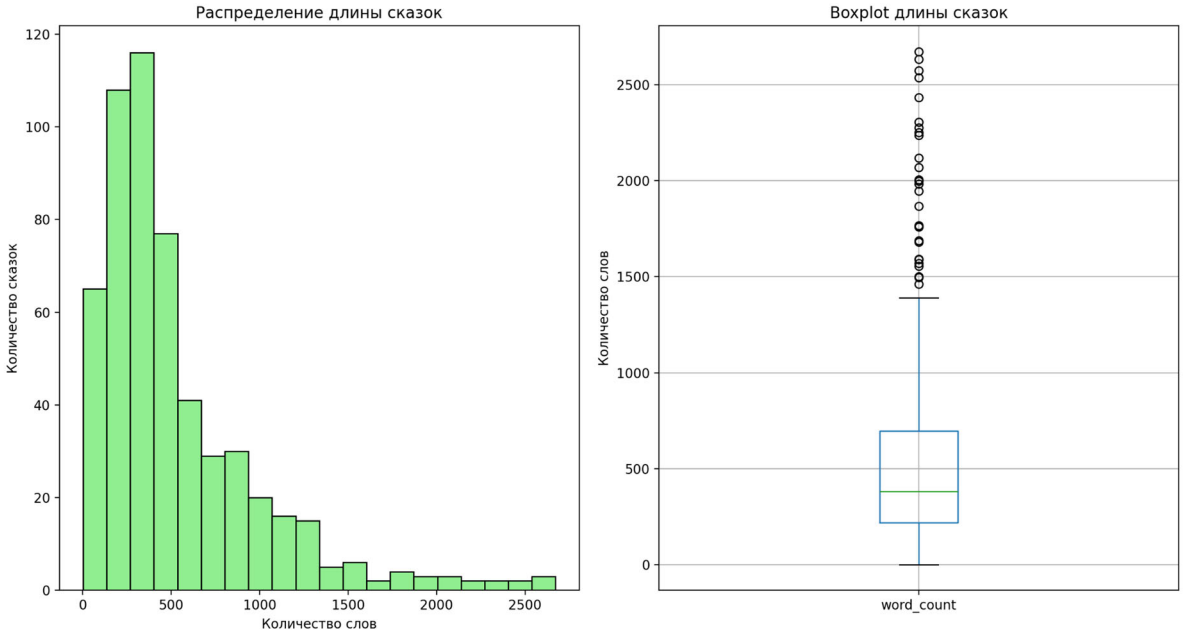

2. Распределение и Boxplot длины сказок.

Количественные параметры текстов показали, что средний объем произведения (с учётом предобработки по стоп-словам) составляет 530 слов, при этом диапазон сказок: от минимальных (20 слов) до развернутых

повествований (2757 слов). Результаты анализа длины сказок также отдельно вынесены в Приложение 3.

Полученные данные создают статистически репрезентативную основу для последующего стилистического и ключевого анализа.

3.2. Ключевой анализ

Проведенный анализ с применением метрики TF-IDF выявил жанровую специфику лексического состава русских народных сказок.

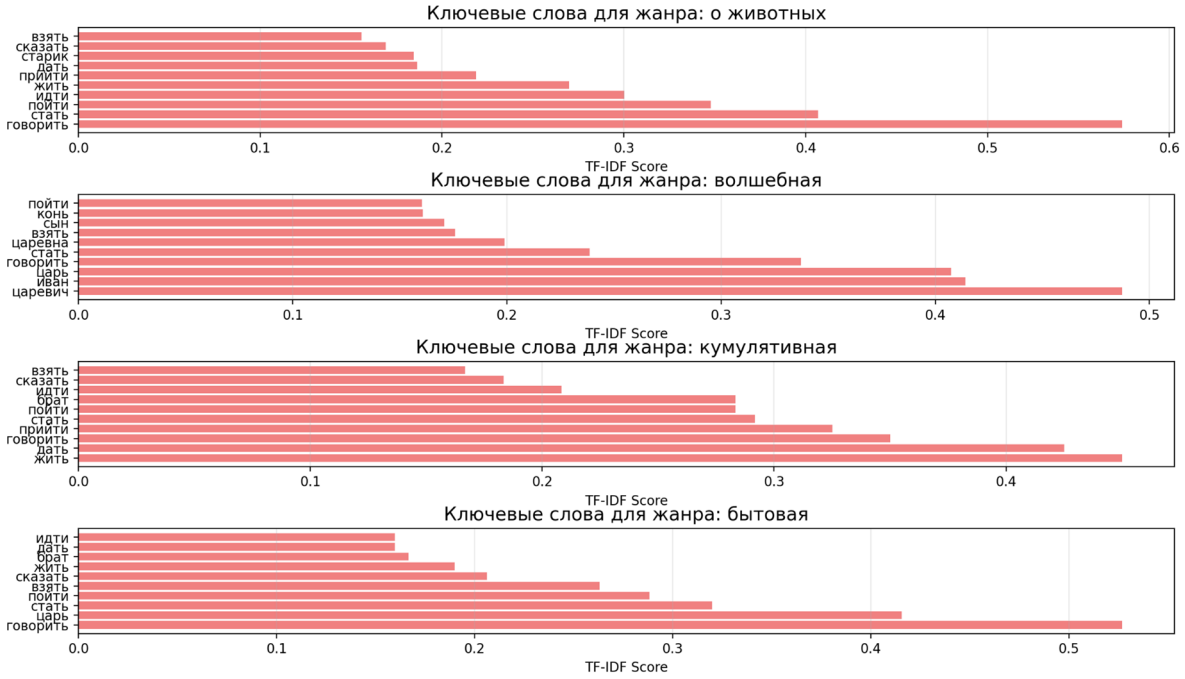

3. Распределение ключевых слов по жанрам.

В результате ключевого анализа было отмечено, что:

1. Волшебные сказки сопровождаются атрибутами власти и статуса: царевич (0.4873), Иван (0.4142), царь (0.4074), царевна (0.1990).

2. Сказки о животных акцентируют действие и взаимодействие: говорить (0.5741), стать (0.4068), пойти (0.3479).

3. Кумулятивные сказки отличаются социальной направленностью: жить (0.4501), дать (0.4251), говорить (0.3501).

4. Бытовые сказки совмещают элементы волшебного и социального: говорить (0.5270), царь (0.4157), стать (0.3200).

Список наиболее значимых слов с TF-IDF показателями приведен в Приложении 4.

Полученные данные свидетельствуют о системном характере лексической организации сказочных жанров, где каждый жанр формирует собственное тематическое ядро, отражающее его специфику и культурные функции.

3.3. Анализ тональности

Для анализа тональности был составлен словарь условно положительных и условно отрицательных слов и оценивалась их доля вхождения в текст каждой сказки.

В результате проверки выяснилось, что общая эмоциональная картина характеризуется нейтральной медианной тональностью (0.000) со смещением в позитивную область (среднее значение 0.026) и значительным разбросом показателей (стандартное отклонение 0.604), что указывает на общую нейтральность сказочного нарратива. Однако жанровая дифференциация выявляет заметные различия.

В сказках о животных прослеживается выраженная негативная тенденция (-0.197), что отражает дидактическую функцию жанра, основанную на демонстрации последствий неправильного поведения. Волшебные сказки имеют умеренную позитивную окраску (0.121), что может соответствовать ориентации жанра на преодоление испытаний. Бытовые сказки имеют нейтрально-негативный характер (-0.019), который обуславливается социальной критикой и иронией, а кумулятивные сказки - позитивную направленность (0.203), связанную с ритмической организацией и комическими элементами.

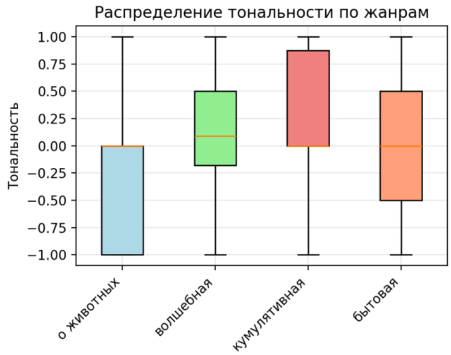

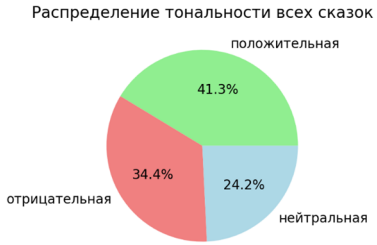

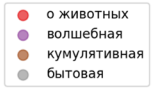

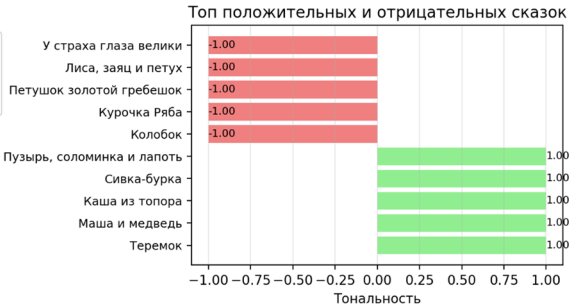

4. Результаты анализа тональности.

Топ положительных и отрицательных сказок, определенных по экстремальным значениям, демонстрирует, что даже между жанрами существует значительный разброс. С полным списком результата анализа тональности можно ознакомиться в Приложении 5.

Важно отметить, что использованный словарный метод имеет ограничения, особенно для архаичных и метафорических текстов. В будущих исследованиях целесообразно применить более сложные модели, учитывающие контекст, а также способные отслеживание изменение эмоционального окраса текста от начала к концу сказки.

3.4. Обсуждение результатов

Проведённые частотный анализ показал удивительное соответствие между raw-статистикой и теорией В.Я. Проппа. Оказалось, что ключевые нарративные функции имеют четкие лексические маркеры:

1. Глаголы коммуникации (говорить, сказать) вербализуют функции «оповещения» и «обмана».

2. Глаголы действия (взять, дать, идти, пойти) материализуют функции «получения волшебного средства», «перемещения», «трансфера».
3. Глагол «стать» отражает функцию «трансформации» и изменения статуса.
4. Антропонимы (Иван, царевич) соответствуют функции «героя».
5. Лексема «царь» реализует функции «отправителя» и «дарителя».

Общий позитивный сдвиг, отмеченный в результате тонального анализа, может быть коррелятом компенсаторной природы сказки по концепции В.Я. Проппа, однако для подтверждения этой гипотезы требуются методы, анализирующие динамику тональности внутри текста.

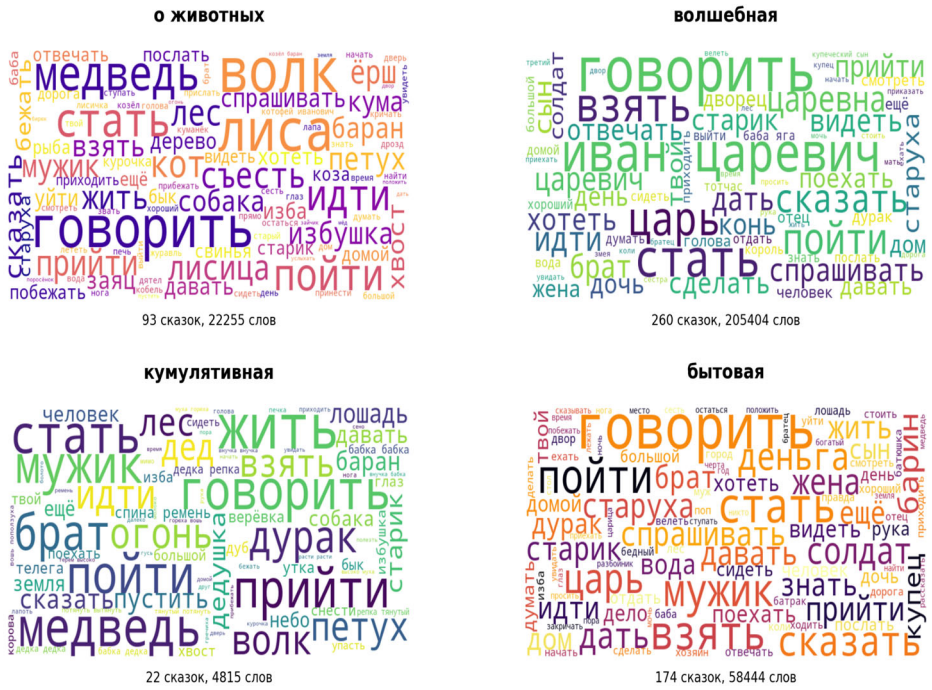

5. Облака слов на основе частотного анализа.

Помимо частотного ядра необходимо отметить и жанровую специфику, которая в свете пропповской типологии приобретает конкретные интерпретации:

1. Волшебные сказки демонстрируют полную реализацию 31 функции с акцентом на аристократии и власти.

2. Сказки о животных редуцируют персонажную систему, сохраняя базовые функции «вредительства» и «ликвидации недостачи».

3. Бытовые сказки трансформируют функции, замещая магические элементы социальными взаимодействиями.

Экстремальные значения тональности в конкретных сказках (Колобок, Теремок) маркируют ключевые сюжетные точки «нарушения запрета» и «наказания».

Таким образом, количественные методы анализа не только подтверждают основные положения морфологической теории сказки, но и раскрывают новые аспекты ее лексико-стилистической реализации, углубляя понимание механизмов функционирования фольклорного текста.

Выявленные закономерности демонстрируют, что структурное единство русского сказочного эпоса, описанное Проппом на уровне нарративных функций, находит прямое отражение в лексико-статистических параметрах текстов.

Заключение

В результате исследования удалось не только выявить устойчивые лексико-стилистические паттерны, но и, по сути, верифицировать классическую теорию Проппа количественными методами. Было доказано, что нарративные структуры — это не умозрительная конструкция, а реальность, отражающаяся в объективной статистике текста.

Так, было установлено коммуникативно-действенное ядро сказочной лексики с доминированием глаголов речи и действия (говорить, стать, пойти) при сохранении традиционных антропонимов (Иван, царь); подтверждена жанровая специфика на лексическом уровне с помощью метода TF-IDF; выявлен позитивный эмоциональный сдвиг в общей тональности сказок при сохранении жанровых различий.

Осуществлена верификация теории В.Я. Проппа количественными методами. Показано, что ключевые нарративные функции («герой», «даритель», «помощник», «перемещение») имеют прямые корреляты в виде лексико-статистических маркеров, что подтверждает структурное единство сказочного эпоса на глубинном уровне.

Автором настоящей работы планируются дальнейшие исследования, а именно сравнительный частотный анализ, использующий сопоставление с корпусом литературных произведений и современного языка; углубленный анализ тональности на основе более сложных языковых моделей; разработка модели машинного обучения для автоматического определения жанра неизвестной сказки.

Таким образом, комбинация традиционных гуманитарных знаний и современных компьютерных методов открывает новые возможности для глубокого и масштабируемого изучения культурного наследия.

Библиографический список

1. Пропп В. Я. Морфология сказки / В. Я. Пропп — Гос. ин-т истории искусств. Л.: Academia, 1928. — 152 с.
2. Норец М. В., Элькан О. Б., Норец Н. К. Взаимодействие искусственного интеллекта и цифровой лингвистики / — М. В. Норец, О. Б. Элькан, Н. К. Норец — LITERA, 2025. — 221-230 с.
3. Андреюк Д.С., Фадеева Е.А., Кузнецова Е.А. Как измерить культурный код? Количественный анализ семантики в сказках А.С. Пушкина и в ценностях российской молодежи / — Д. С. Андреюк, Е. А. Фадеева, Е. А. Кузнецова — Государственное управление. Электронный вестник, 2023. — 151-161 с.
4. Открытый код на GitHub / Режим доступа: https://github.com/monalenka/russian-folklore-ml (дата обращения 08.10.2025)

Приложение 1.

Частотный анализ (слово, количество встречающихся слов во всем корпусе).

Слово	Абсолютная частота	Слово	Абсолютная частота	Слово	Абсолютная частота
говорить	3610	жить	1255	поехать	807
Иван	2578	брат	1111	хотеть	793
стать	2476	конь	1053	старуха	782
царь	2379	старик	1008	дочь	780
царевич	2340	царевна	1003	лес	776
пойти	1829	дать	994	голова	776
взять	1787	спрашивать	939	вода	767
идти	1471	прийти	921	добрый	757
сын	1467	домой	887	мужик	757
сказать	1411	день	828	рука	756

Приложение 2.

Частотный анализ (слово, количество встречающихся слов по жанрам).

О животных		Волшебная		Бытовая		Кумулятивная	
волк	380	Иван	2440	говорить	835	жить	54
лиса	351	говорить	2431	стать	507	дать	51
говорить	302	царевич	2324	пойти	457	говорить	42
медведь	246	царь	1943	царь	436	прийти	39
стать	214	стать	1720	взять	417	медведь	36
пойти	183	взять	1268	мужик	412	стать	35
идти	158	сын	1230	сказать	327	пойти	34
кот	151	пойти	1155	жить	301	брат	34
Уник. слов: 4214		Уник. слов: 14226		Уник. слов: 7974		Уник. слов: 1570	

Приложение 3.

Анализ длины сказок.

Общее количество слов (после предобработки): 290918, средняя длина: 529.9 слов.

Длина сказки	count	mean	min	max
короткая	86	111.3	20	294
средняя	385	455.7	90	2432
длинная	78	1357.6	632	2672

Приложение 4.

Ключевой анализ (слово, TF-IDF метрика)

О животных		Волшебная		Бытовая		Кумулятивная	
говорить	0.5741	царевич	0.4873	говорить	0.527	жить	0.4501
стать	0.4068	Иван	0.4142	царь	0.4157	дать	0.4251
пойти	0.3479	царь	0.4074	стать	0.32	говорить	0.3501
идти	0.3003	говорить	0.3374	пойти	0.2884	прийти	0.3251
жить	0.2699	стать	0.2387	взять	0.2632	стать	0.2917
прийти	0.2186	царевна	0.199	сказать	0.2064	брат	0.2834
дать	0.1863	взять	0.176	жить	0.19	пойти	0.2834
старик	0.1844	сын	0.1707	брат	0.1666	идти	0.2084
сказать	0.1692	конь	0.1607	дать	0.1597	сказать	0.1834
взять	0.1559	пойти	0.1603	идти	0.1597	взять	0.1667

Приложение 5.

Анализ тональности.

Средняя тональность: 0.026, медиана: 0.000, стандартное отклонение: 0.604

жанр	mean	std	count
Бытовая	-0.019	0.643	174
волшебная	0.121	0.501	260
Кумулятивная	0.203	0.606	22
О животных	-0.197	0.718	93

Топ-3 положительных сказок (жанр)	Топ-3 отрицательных сказок (жанр)
Теремок (кумулятивная)	Колобок (о животных)
Маша и медведь (волшебная)	Курочка Ряба (бытовая)
Каша из топора (бытовая)	Петушок золотой гребешок (о животных)